



南京理工大学
NANJING UNIVERSITY OF SCIENCE & TECHNOLOGY

毕业设计说明书

作 者： 闵大为 学 号： 1102610118

学 院： 计算机科学与工程学院

专业(方向)： 软件工程专业(人工智能方向)

题 目： 基于 PCANet 模型的道路识别

指导者： 王欢 讲师
(姓 名) (专业技术职务)

(姓 名) (专业技术职务)

评阅者： (姓 名) (专业技术职务)

2015 年 5 月

声 明

我声明，本毕业设计说明书及其研究工作和所取得的成果是本人在导师的指导下独立完成的。研究过程中利用的所有资料均已在参考文献中列出，其他人员或机构对本毕业设计工作做出的贡献也已在致谢部分说明。

本毕业设计说明书不涉及任何秘密，南京理工大学有权保存其电子和纸质文档，可以借阅或网上公布其部分或全部内容，可以向有关部门或机构送交并授权保存、借阅或网上公布其部分或全部内容。

学生签名：

年 月 日

指导教师签名：

年 月 日

毕业设计说明书中文摘要

本文详细分析了 PCANet 模型，给出了一种基于 PCANet 模型的道路识别方法。该方法利用 PCANet 模型进行提取特征，使用支持向量机进行图像分类。针对该方法中存在的虚警和漏检问题，我们设计了一种基于道路位置先验的虚警去除方法，并利用道路区域的一致性降低漏检率。通过实验统计分析，我们对方法中的关键参数进行了优化选取。大量实验结果证明：PCANet 模型可用于道路区域特征提取，基于 PCANet 模型的道路识别方法是有效的，且道路先验知识对识别效果有较好的提升作用。

关键词 道路识别 PCANet SVM 先验信息

毕 业 设 计 说 明 书 外 文 摘 要

Title Road Recognition Based on PCANet Model

Abstract

This paper studied the PCANet model and presented a road recognition method based on PCANet model. The method uses the PCANet model for feature extraction, and uses the SVM for image classification. In order to solve the problem that the recognition results contain false alarm and missing alarm, we devised a method based on road position priori information to remove false alarm, and used the consistency of road area to reduce the missing rate. Through experiments statistical analysis, the key parameters of the method were optimized and selected. A large number of experimental results prove that the PCANet model can be used to extract road features, the road recognition method based on PCANet model is effective, and the road priori information has greatly improved the recognition results.

Keywords Road Recognition, PCANet, SVM, Priori information

目 次

1 绪论.....	1
1.1 课题背景与研究意义.....	1
1.2 国内外发展现状.....	1
1.3 本文的工作及贡献.....	2
1.4 本文的结构安排.....	3
2 基于 PCANet 模型的道路识别.....	4
2.1 PCANet 模型.....	4
2.1.1 PCANet 模型介绍.....	4
2.1.2 算法复杂度分析.....	7
2.2 支持向量机.....	8
2.2.1 支持向量机介绍.....	8
2.2.2 支持向量机使用.....	9
3 引入先验信息的基于 PCANet 模型的道路识别.....	11
3.1 先验信息的引入.....	11
3.2 选择道路形状模板去除虚警.....	13
3.2.1 虚警去除过程.....	13
3.2.2 模板库的构建.....	14
3.2.3 模板选择算法.....	16
3.3 道路连通性检测降低漏检率.....	18
4 实验及评价.....	20
4.1 实验环境.....	20
4.1.1 编译和运行环境.....	20
4.1.2 程序参数.....	20
4.1.3 实验数据.....	21
4.2 程序界面.....	23
4.3 实验结果及评价.....	25
4.3.1 PCANet 模型的训练结果及评价.....	25
4.3.2 引入先验信息后模型的定量分析.....	25
4.3.3 引入先验信息后模型的定性分析.....	29
结 论.....	34
致 谢.....	35
参 考 文 献.....	36

1 绪论

1.1 课题背景与研究意义

随着智能交通技术的发展，道路识别在多个领域都具有越来越重要的作用^[1]。在军事中，道路识别技术有利于开辟战场通道；在地震灾害救援中，道路识别技术可以帮助判断道路的受损情况；在智能车系统中，道路识别技术能帮助智能车导航，相当于智能车的视觉系统。由此可见，对于道路识别方法的研究是很有意义的。

获取道路相关信息的方式主要包括视觉、激光、雷达、超声波等方法，其中激光和超声波的原理抗干扰能力较差，雷达存在路面发射率不一样的问题。视觉信号全面地包含道路中的信息和特征，特别是对于结构化道路，场景较为简易，目标突出，通过采用适当的图像处理算法可以有效地检测出目标，同时处理成本相对较低。因此，利用机器视觉进行汽车自动驾驶是目前智能汽车的最合适的方案^[2]。本文研究的道路检测方法就是基于视觉图像的。

本文对于这个课题的研究也是为了能够有效地检测出图像中的道路区域，从而为智能车的自动导航服务。

1.2 国内外发展现状

道路识别技术是智能车辆技术中的一个重要研究领域。早在 20 世纪 50 年代初，美国的一家公司就开始了智能车辆技术的研究^[3]。从 20 世纪 80 年代开始，智能车辆技术开始迅速发展，取得了许多进展，如美国研发了 NavLab 系统、意大利研发了 ARGO 系统、德国研发了 VaMP 车辆系统^[4]。其中 Carnegie-Mellon 大学（CMU）开发的 SCARF 视觉系统表现很出色。跟国外相比，国内的研究起步较晚，比较重要的研究有：清华大学研发了 THMR 系列移动机器人系统^[5]。

通过查阅文献，可以发现很多道路检测方法都是通过边缘检测或区域检测入手，主要依据道路的一些特征，如轮廓线，颜色值等。^[1]，^[2]，^[5]，^[6]这些文章中就采用了边缘检测来进行道路区域的识别。在道路检测方法中，处理效果比较好的算法有道路边缘 Hough 变换提取法、模板法、路面重建算法、区域生长法等，其他的一些算法如神经网络等，也具有不错的处理效果^[5]。由于实际检测过程中的道路区域具有多样性的特点，如：不同材料的路面有不同的颜色，有些路面没有行道线等，因此目前道路识别算法的通用性还不是很好。所以本文希望通过引入 PCANet 模型和机器学习技术增强道路识别的效果和通用性。

下面给出一些具体地研究：

邓维^[1]通过阈值分割等图像处理技术来获得图像骨架的方法进行道路区域识别。为了提高效果，对均值滤波算法进行了改进。图像处理过程中对图像进行了对比度增强，进行了去噪处理，并使用改进后的均值滤波算法进行处理，最后通过阈值分割获得图像骨架。

朱钊^[2]通过提取结构化道路的车道线来确定道路区域的。为了提高处理的效率，在预处理阶段对图像进行了灰度变换，并划分出图像的有效区域，从而减少了处理量。在处理过程中使用了 Sobel 边缘增强算法，并增强了图像的对比度。最后通过最小二乘法和 Hough 变换相结合的方法来寻找道路中的车道线。

王忠^[5]提出了一种将道路边缘信息和颜色信息相结合的道路区域识别方法。该方法中结合的颜色信息可以验证边缘检测的效果，能够提升边缘检测的鲁棒性。并且提出了道路区域中心区域的概念来解决道路中存在障碍物等问题。此外，还提出了基于线段端点检测的 Hough 变换改进算法，该算法能够解决障碍物位置难以确定的问题。

杨正帅^[18]通过结合边缘检测和区域生长的方法进行道路边缘区域的检测和道路区域的识别。根据道路区域的边线在空间位置上具有相同或相近的特点，可以确定物体在道路中的位置。该检测方法针对的是直线道路模型，主要利用 Hough 变换提取特征直线。

1.3 本文的工作及贡献

本文最终提出了一种引入先验信息的基于 PCANet 模型的道路识别方法，所做的主要工作和贡献如下：

1) 给出了一种基于 PCANet 的道路识别方法。

为了提供一种有效的道路识别方法，收集了大量道路和非路区域的样本用于识别模型的训练，并详细研究了 PCANet 模型算法，使用 C++ 编程实现了其具体算法，该算法包括模型的训练和利用训练好的模型进行识别两个部分，最后对提出的道路识别方法进行了定性和定量的评价。

2) 给出了一种基于道路位置先验的虚警剔除方法。

为了去除道路识别结果中的虚警，本文给出了一种基于道路位置先验的虚警剔除方法。该方法需要选择道路形状相近的模板，本文设计和实现了图像块数量固定和变动的两种模板选择算法，并通过实验对其效果进行了分析。

3) 给出了一种基于道路区域一致性的漏检率降低方法。

为了利用道路区域的一致性降低检测结果中的漏检率，本文给出了一种使用广度搜索算法检测区域连通性从而来判断区域一致性的漏检率降低方法。

1.4 本文的结构安排

本文的结构安排如下：

第一章主要介绍了课题相关背景、研究意义、国内外发展现状和本文所做的工作。

第二章详细介绍了 PCANet 模型对数据的处理过程及其算法复杂度，并简单介绍了 SVM 及其使用方法。

第三章对基于 PCANet 模型的道路识别方法的初步处理结果进行了分析，为了解决处理结果中存在的虚警和漏检问题，设计了一种基于道路位置先验的虚警去除方法，并利用道路区域的一致性降低漏检率。

第四章对实验环境和实验数据进行了介绍，并着重分析了实验结果。

2 基于 PCANet 模型的道路识别

本章包括利用 PCANet 模型提取图像特征和使用提取出来的图像特征对支持向量机进行训练。接下来将介绍作为特征提取器的 PCANet 模型和作为特征训练器的支持向量机。

2.1 PCANet 模型

2.1.1 PCANet 模型介绍

PCANet 是最近提出的一个简单的深度学习网络，可以用于图像分类而且效果很好^[13]。该网络提取道路图像特征的主要步骤是：首先利用 PCA（主成分分析）来获得模型的多级滤波器(multistage filter banks)，然后用滤波器去过滤原图像，接着用二进制哈希(binary hashing)和分块直方图(block histograms)分别做索引和合并，最后得到输入图片的特征向量，利用这些特征向量可以训练 SVM，训练好的 SVM 可以用来进行图像分类。

2.1.1.1 利用 PCA 获得多级滤波器

在 PCANet 模型中使用了 PCA 方法来获得多级滤波器，下面先介绍一下 PCA。

PCA 是 Principal Components Analysis 的简称，表示主成分分析，是一种在最小均方意义下寻找最能代表原始数据的投影方法。PCA 的主要原理是通过相关方法找到数据的主轴方向，由找到的主轴构成一个新的坐标系，然后把数据从原来的坐标系向新的坐标系投影，投影的过程可以降低数据的维数。在图像处理中，特征向量的维数往往很高，而这之中的很多维是冗余或者无效的，此时就需要 PCA 了，PCA 的主要作用就是用于特征向量的降维。这个算法在人脸识别方面具有很好的效果。

PCANet 中通过 PCA 获得相应滤波器的算法步骤如下：

- 1) 对输入图像进行分块处理，将每个小块转换成列向量。
- 2) 计算所有列向量的平均值。
- 3) 计算每一列向量与该列向量的平均值的差值。
- 4) 构建协方差矩阵。求协方差矩阵的特征向量和特征值。选取前 L_i (L_i 为第 i 阶段滤波器数量) 个最大特征向量组成特征空间。

课题研究中引入的 PCANet 模型通过以上的算法来获得相应的滤波器。这些滤波器可以降低图像的特征向量的维数，提取出有用的特征，为之后 SVM 的训练和识别提供数据输入。

2.1.1.2 PCANet 特征提取过程

通过 PCA 方法获得滤波器后，就可以通过整个 PCANet 模型来提取特征了。图 2.1 是 PCANet 模型提取图像特征向量的过程图。

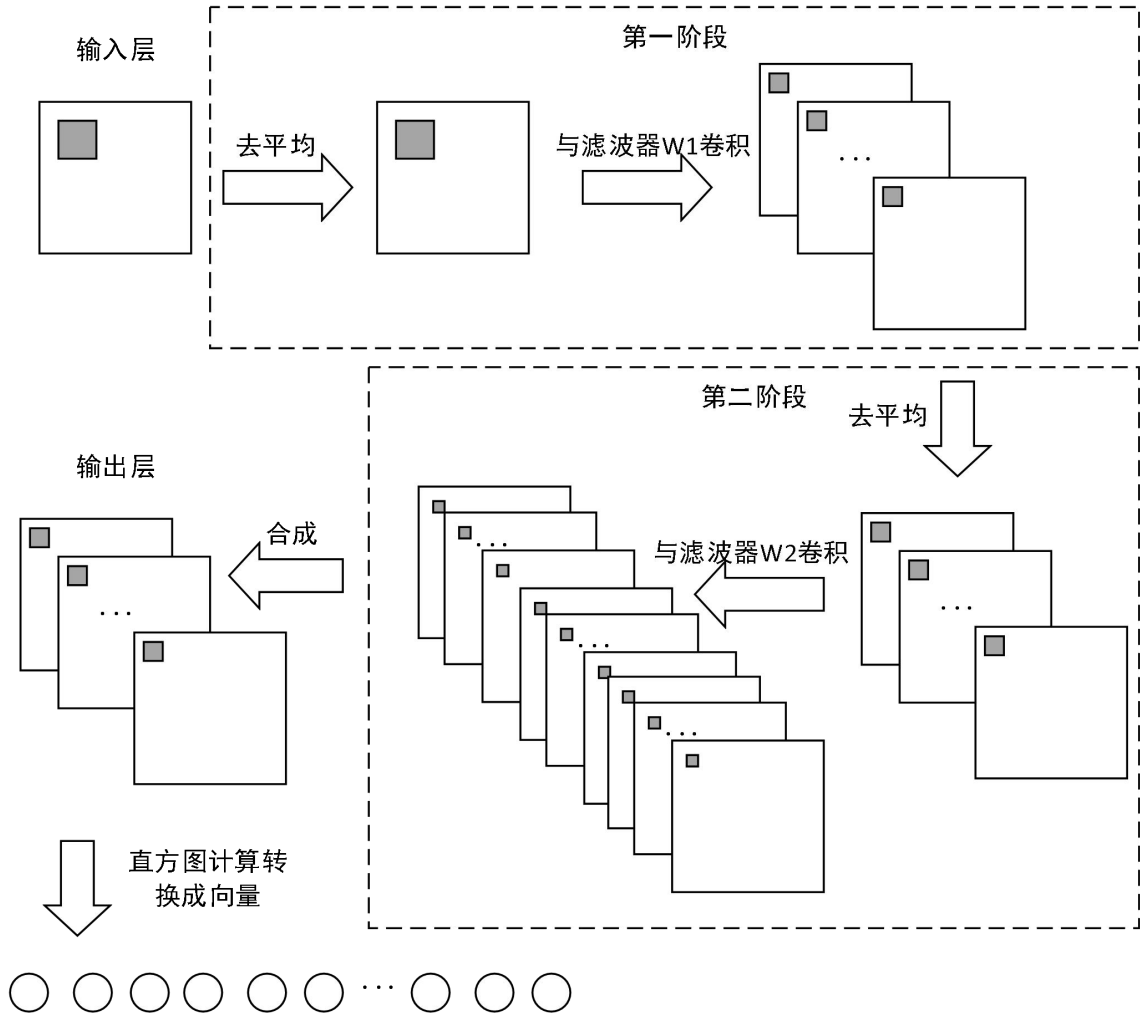


图 2.1 两阶段 PCANet 流程框图

用 C++ 编程实现的 PCANet 模型的算法步骤如下：

- 1) 对输入图像进行分块处理，将每个小块转换成列向量，并且去平均。
- 2) 与第一阶段的滤波器进行卷积。
- 3) 将第一阶段的输出图像作为第二阶段的输入图像，将第一阶段的滤波器替换为第二阶段的滤波器，其余不变，重复上述步骤。
- 4) 将结果图像二值化并合并成十进制，统计直方图矩阵。将直方图转换为向量。该向量就是经过 PCANet 模型提取到的特征向量。

图 2.2 中以一个输入图像块为例展示了特征提取的过程。实验中，输入的是一个大小为 28×28 的图像块 I_{in} 。处理过程为：首先，填充边界变为 I_{ext} ，这样是为了更好地利用图像信息；然后，使用小块对填充后的图像进行分块，并且去掉平均值：

$$I_t = [\bar{I}_{ext,1}, \bar{I}_{ext,2}, \dots, \bar{I}_{ext,num}] \quad (1)$$

其中 $\bar{I}_{ext,i}$ 表示去掉平均值并转换成列向量的图像块，num 表示图像块的个数，与进行分块时的移动步长和小块大小有关， I_t 表示图像的处理结果集合。需要注意的是，以上针对的是灰度图像，灰度图像只有一个颜色通道，如果实验中是对彩色图像进行处理，那么将有三个颜色通道：

$$I_t = [I_{t,r}, I_{t,g}, I_{t,b}] \quad (2)$$

接着，使用学习得到的滤波器对分块后的图像进行处理，并重塑形状：

$$I_r = \text{Re}(I_t * W_1) \quad (3)$$

其中 W_1 表示第一阶段的滤波器， $\text{Re}(x)$ 表示对图像 x 重塑形状， I_r 表示处理结果， I_r 内部是由 L_1 幅图像组成的：

$$I_r = [I_{r,1}, I_{r,2}, \dots, I_{r,L_1}] \quad (4)$$

可见，原来的一幅图像经过这几个步骤后就变为 L_1 (示例中 $L_1 = 8$) 幅图像，到此第一阶段处理完成；之后这 8 幅图像作为第二阶段的输入，除了使用的滤波器不同，其余处理过程与第一阶段相同，经过第二阶段处理后，每幅图像又生成了 L_2 (示例中 $L_2 = 8$) 幅图像，总共 $L_1 L_2 = 64$ 幅图像：

$$A = [I_{r,1,1}, \dots, I_{r,i,j}, \dots, I_{r,L_1,L_2}], i = 1, 2, \dots, L_1, j = 1, 2, \dots, L_2 \quad (5)$$

为了描述方便，将上式记为：

$$A = \{R_{i,j}\}, i = 1, 2, \dots, L_1, j = 1, 2, \dots, L_2 \quad (6)$$

其中 A 表示图像处理结果集合， $R_{i,j}$ 表示第一阶段第 i 幅输出图像经过第二阶段处理后的第 j 幅输出图像。然后根据权重 $2^0 \sim 2^{L_2-1}$ 将 $L_1 L_2$ 幅图合成为 L_1 幅图：

$$S_i = \sum_{j=1}^{L_2} 2^{j-1} R_{i,j}, i = 1, 2, \dots, L_1 \quad (7)$$

其中 S_i 表示合成后的图像，在合成之后再进行直方图分块，分块之后进行直方图统计，最后转换为特征向量：

$$V_i = \text{Con}(\text{Cal}(H(S_i))), i = 1, 2, \dots, L_1 \quad (8)$$

其中 $H(x)$ 表示对象图像 x 进行直方图分块， $\text{Cal}(y)$ 表示对分块结果 y 进行直方图统计，

$Con(z)$ 表示将统计结果 z 转换为特征向量， V_i 表示输入图像的特征向量中的第 i 个特征段，总共有 L_1 个特征段。




图 2.2 特征提取过程示例

2.1.2 算法复杂度分析

PCANet 模型是一个简单并且有效的模型，接下来将对 PCANet 模型的复杂度进行一下分析。先介绍一下分析用到的变量参数：有 N 幅输入的图片 $\{I_i\}_{i=1}^N$ ，大小为 $m \times n$ (28×28)，在所有的阶段块大小（或者说 2D 滤波器大小）是 $k_1 \times k_2$ (7×7)，移动步长是 $b_1 = 1$ ， $b_2 = 1$ ，统计直方图矩阵时覆盖的块的大小是 $K_1 \times K_2$ (8×6)。以下分析针对一幅图像 ($N = 1$)。

2.1.2.1 获得滤波器复杂度

首先分析一下 PCANet 模型获得相应滤波器的算法复杂度。该算法先将每个输入图像分块，然后将每个图像块的像素矩阵拉成列向量，最后得到的矩阵行数为 $k_1 k_2$ ，列数为 mn ；接

着计算所有列向量的平均值并且去平均，复杂度为 $O(k_1 k_2 mn)$ ；然后构建协方差矩阵，矩阵大小 $k_1 k_2 * k_1 k_2$ ，计算复杂度为 $O((k_1 k_2)^2 mn)$ ；最后求出协方差矩阵的特征向量和特征值，选取出前 L 个最大特征向量组成特征空间，特征值分解的复杂性是 $O((k_1 k_2)^3)$ 。所以这个阶段的复杂度为 $O(k_1 k_2 mn + (k_1 k_2)^2 mn + (k_1 k_2)^3)$ ，由于实验中 $mn \gg k_1 k_2$ ，所以复杂度为 $O((k_1 k_2)^2 mn)$ 。

2.1.2.2 获得特征向量复杂度

其次分析一下 PCANet 模型获得图片特征向量的算法复杂度。该算法也先将每个输入图像分块，并将每个图像块的像素矩阵拉成列向量，最后得到的矩阵行数为 $k_1 k_2$ ，列数为 mn ；接着与第一阶段的滤波器进行卷积，复杂度为 $O(L_1 k_1 k_2 mn)$ ；然后将第一阶段的输出图像作为第二阶段的输入图像，共 L_1 幅图像，第二阶段处理与第一阶段相似，只是滤波器和输入图像不同，复杂度为 $O(L_1 L_2 k_1 k_2 mn)$ ；之后将结果图像二值化并合并成十进制，统计直方图矩阵，将 L_2 位二进制转换成十进制数复杂度为 $O(L_1 L_2 mn)$ ，此时图像数量由 $L_1 L_2$ 块变为 L_1 块；接着进行分块，分块后大小为 $K_1 K_2 \times B$ （ B 为每幅图像分块后的块数），并转换为直方图矩阵，大小变为 $2^{L_2} \times B$ ，赋值复杂度为 $O(K_1 K_2 B L_1)$ ；最后将直方图转换为列向量，赋值复杂度是 $O(2^{L_2} B L_1)$ 。由于实验中 $K_1 K_2 < 2^{L_2}$ ，这个阶段的复杂度为 $O(L_1 L_2 k_1 k_2 mn + 2^{L_2} B L_1)$ ，又因为实验中 $L_2 k_1 k_2 mn > 2^{L_2} B$ ，所以复杂度简化为 $O(L_1 L_2 k_1 k_2 mn)$ 。

2.1.2.3 总体复杂度

根据以上分析可知，在本文的实验中，如果用 N_1 幅图像来训练获得滤波器，则训练过程的复杂度为 $O(N_1 (k_1 k_2)^2 mn)$ ，再对 N_2 幅图像提取特征，复杂度为 $O(N_2 L_1 L_2 k_1 k_2 mn)$ 。所以整个 PCANet 网络模型的复杂度为 $O(N_1 (k_1 k_2)^2 mn + N_2 L_1 L_2 k_1 k_2 mn)$ 。

2.2 支持向量机

2.2.1 支持向量机介绍

支持向量机的英文名称是 Support Vector Machine，简称 SVM。在数据分类问题中，对 n 维数据，我们希望用小于 n 维的超平面去区分数据。能够把数据区分开的平面有多个，所以如何定义分类的好坏一直是一个难题。图 2.3 显示的是：在二维平面中，满足分类要求的直

线可以有 multiple。




图 2.3 二维平面多条分类直线

在 SVM 中，为了解决定义分类好坏的问题，引入了间隔（margin）的概念：训练的数据点到分类边界的最近距离。SVM 就是在满足分类的超平面中找出间隔最大的那个平面。也就是满足下面的式子：

$$\min \frac{1}{2} \|w\|^2 \quad s.t. \quad y_i(w \cdot x_i + b) \geq 1, i=1,2,\dots,n \quad (9)$$

其中， x_i 表示输入变量， y_i 表示输出值， w ， b 是平面 $w \cdot x + b = 0$ 的参数。由于这个平面与距离这个平面最近的那些训练数据有关，与其他的数据点无关，所以这些最近的数据点也被称为“支持向量”。系统中我们并没有自己编程实现 SVM 的细节，而是调用了 OpenCV（Open Source Computer Vision Library）中的 SVM，所以不再详细介绍其基本原理。

2.2.2 支持向量机使用

在识别系统中，我们使用了 OpenCV（Open Source Computer Vision Library）中提供的 SVM。系统分为训练和识别两个阶段。在训练阶段，我们提供图像的特征向量和类别标签，进行训练，训练结束后保存训练结果。在识别阶段，我们读取之前的训练结果，得到训练好后的支持向量机，然后根据要识别的特征向量进行类别判断。SVM 使用流程图见图 2.4。

图 2.4 中的已知特征向量是图像经过 PCANet 模型处理后的输出结果，已知的类别标签是人工事先标记的，识别出的类别标签是 SVM 根据已知的特征向量和之前的学习结果进行预测得到的。SVM 参数是需要设置的，不同的参数具有不同的学习效果，在实验中，经过多次测试，最终确定了 SVM 的主要参数：SVM 的类型选择 C 类支持向量分类机，SVM 类型的参数 C 取 15，核函数类型选择线性，最大迭代次数是 100，结果的精确性是 e^{-6} 。其余为 OpenCV

中 SVM 的默认值，不进行设置。




图 2.4 SVM 使用流程

3 引入先验信息的基于 PCANet 模型的道路识别

本章针对识别结果中存在虚警和漏检的问题，采用引入道路区域先验信息的方法来减少虚警数和降低漏检率。本章首先将详细介绍引入先验信息的原因和引入后的总体设计，然后将介绍如何选择道路形状模板去除虚警，最后介绍如何利用道路连通性检测降低漏检率。这两个具体实现部分的算法都经历了从简单到复杂的过程。

3.1 先验信息的引入

在第 2 章中我们介绍了“基于 PCANet 模型的道路识别”的两个重要组成部分：PCANet 模型和支持向量机（SVM）。根据第 2 章中介绍的基本理论，可以得到道路识别的初步过程：输入图片进行分成多个小块图像，然后经过 PCANet 模型处理得到特征向量，再用 SVM 识别特征向量就得到了相应的类别，根据类别（道路区域类别是 1，非道路区域类别是 2）对图片进行黑白染色，最后将黑白小块拼接成检测结果。图 3.1 是输入的图片，图 3.2 是经过以上处理后初步识别的结果，识别结果中黑色区域是非道路区域，白色区域是道路区域。



图 3.1 输入图片



图 3.2 初步识别结果

由图 3.1 和 3.2 可知，虽然识别效果不错，但是初步识别结果还存在两个问题：一是背景区域中不该出现道路区域的地方出现了道路区域，这些背景中的检测出的道路部分称为虚警；

二是道路区域中的一些道路块没有检测出来，这些没有检测出来的道路块称为漏检。为了解决这两个问题，本文在识别方法中又引入了道路的先验信息来辅助识别，主要包括道路模板选择和连通性检测这两个部分。道路形状模板选择这个部分是为了去除背景中的虚警，道路连通性的检测这个部分是为了去除道路区域中的漏检。

引入先验信息后的道路的识别方法的总体设计如图 3.3 所示。编程实现的识别程序的外部输入是待识别的道路图片，输出是将道路区域和非道路区域区分开后的黑白图片。整个识别方法的内部结构主要包括：PCANet 处理模块，SVM 类别判断模块，先验信息辅助识别模块。PCANet 处理模块实现了 PCANet 模型，能够针对输入的图片提取出有效的特征向量。SVM 判断类别模块可以根据特征向量和事先的学习到的特征向量的特点来判断出该特征向量是否属于道路区域。先验信息辅助识别模块可以根据识别的结果选择一个最相近的道路形状模板来去出背景中的虚警，根据道路区域连通性的检测也可以改正一些识别错误的的连通区域。第 2 章中已经介绍了 PCANet 处理模块和 SVM 类别判断模块，接下来的几节将具体地介绍先验信息辅助识别模块。

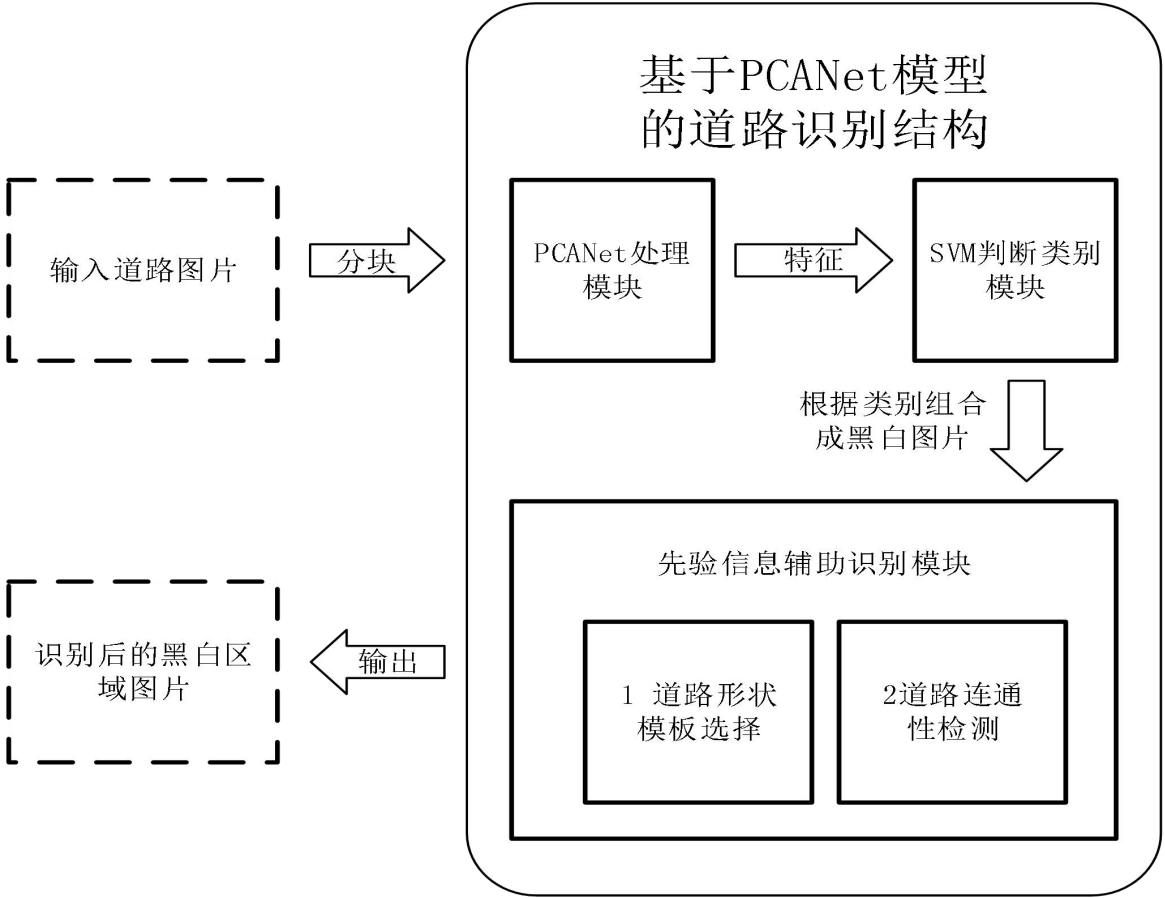


图 3.3 引入先验信息后的模型整体结构

3.2 选择道路形状模板去除虚警

道路形状模板选择这个部分是为了去除背景中的虚警。虚警就是原来非道路区域的地方检测出了道路，为了去除虚警，我们希望知道哪些地方是非道路区域。道路的形状虽然千差万别，但是总体上可以近似地归为几个类别，所以本文在实验中引入了道路形状的模板库来去除虚警。

3.2.1 虚警去除过程

图 3.4 介绍了去除检测结果中的虚警的过程。大致流程如下：首先从模板库中选择与输入图像相近的模板，然后将具有虚警的图像与适合的模板相与（白色区域为信号 1，黑色区域为信号 0），最后得到去除虚警后的图像。具体计算公式如下：

$$y = \begin{cases} 0, & T=0 \\ x, & T=1 \end{cases} \quad (10)$$

其中， T 表示模板部分对应区域的信号值， x 表示输入信号， y 表示输出值。




图 3.4 去除虚警流程

以下图像是实验中处理过程的一个示例。图 3.5 是图像经过 PCANet 模块处理后得到的结

果，是具有虚警的图像。图 3.6 是通过选择算法选取的相近的模板。图 3.7 是具有虚警的图像与模板进行相与，去除虚警后的图像。



图 3.5 具有虚警的图像



图 3.6 选择的模板示例



图 3.7 去除虚警的图像

3.2.2 模板库的构建

实验中的模板库是根据输入图像对应的黑白图片转换而成的。在实验中，每一幅原始图像都有一幅自带的黑白图像，如图 3.10。这幅图像用白色标记出了道路区域，用黑色标记出了非道路区域。在实验中，PCANet 模块处理的结果是由小块组合起来的黑白图像，所以选用的模板也应是由小块组合起来的黑白图像。因此，在实验中我们还编写了原始黑白图像的块状化程序：将原始黑白图像分块，分块后，根据黑白像素所占比例对小块进行染色，这样就

将原始的黑白图像转换成了块状化后的模板图像。

3.2.2.1 单一模板

开始时，模板库的选择方案是将 287 幅原始黑白图像累加，初始的时候每个像素对应位置都为 0，对于每一幅图片，如果某个像素是白色区域，则对应位置加 1，如果是黑色区域，则对应位置加 0。最后根据阈值（实验中为 2）对矩阵进行处理，如果某个位置的值大于等于 2，则将该小块的全部像素点染为白色（道路区域），否则染为黑色（非道路区域）。这个过程本质上是去除了只出现一次的道路区域，并将所有图片的道路区域反应在黑白图片上，结果如图 3.8 所示。然后将该图块状化，得到的结果如图 3.9 所示。图 3.9 所示就是实验开始时中模板库中的全部模板，只有一幅，它将所有 287 幅的道路黑白信息综合反映在了一幅图像中。该模板的特点是：去除的虚警部分基本都是应该去除的，即不会去除不该去除的道路区域，但是由于是所有图片区域的叠加，面积较大，所以这个综合模板的去除虚警效果不是很明显。



图 3.8 原始黑白图像累加阈值化结果



图 3.9 黑白图像累加阈值化块状化后的模板

3.2.2.2 多个模板

为了更好地利用每幅图像的形状信息，又提出了一种每幅图像都生成一个模板的方案。图 3.10 是每幅输入图像自带的原始黑白图像，对其块状化后，得到的模板如图 3.11 所示。与

3.9 相比，该模板的道路区域更小，能够更好地去除虚警部分，但是由于模板由 1 幅增加到 287 幅，我们需要对模板进行选择，如果选择错误，也可能去除正确的道路区域，反而会造成识别效果的降低。



图 3.10 原始黑白图像



图 3.11 块状化后的模板

3.2.3 模板选择算法

去除虚警这个模块最关键的部分是从模板库中选择最相近的模板。实验中采用的方法是，选取一些具有代表性的图像块带入模板中，计算符合程度，选取错误个数最少的或者选取正确个数最多的模板。

3.2.3.1 图像块数量固定的模板选取算法

开始时采用的是图像块数量固定的模板选取算法，其过程如下：

- 1) 找到所有这样的图像块：上下左右都是道路区域块而且本身也是道路区域块。
- 2) 在这些块中随机选出一个道路块。
- 3) 在所有道路区域的图像块中，根据 RGB 的平均值的相似度寻找与 2) 中选取的道路块最相似的 20 个道路块。
- 4) 采用步骤 1)，2)，3) 相同的方法选取出 20 个非道路区域的图像块。
- 5) 将 20 个道路块和 20 个非道路块带入所有的图像模板中，找出错误个数最少的模板。

如果有多个模板符合要求，则随机选取一个。

在算法中，如果只是选取道路区域的图像块，那么道路区域大的模板的符合度会最高，其他模板将失去作用，同理如果只是选取非道路区域的图像块也会导致非道路区域最大的模板总是被选中，因此实验中同时选取了道路区域和非道路区域的图像块，这样可以解决道路区域大或非道路区域大的模板被选中概率大的问题。

3.2.3.2 图像块数量变动的模板选取算法

图像块数量固定的算法由于图像块较少，找到的模板不是特别准确，所以我们希望通过增加图像块的数量来提高模板选择的准确率。但是图像块数量多少才足够那？只是把 40 个样本增加到 100 或者 200 或者更多是不够好的，因为道路区域可能没有那么多的图像块，当图像块数量很大时可能会把很多边缘的虚警带入，反而影响实验效果。由于考虑到连通性检测可以将边缘的虚警去掉而且能找到连续的道路区域，所以本文采用的方法是：通过连通性检测来寻找最大的道路和非道路区域，然后将这些区域中的图像块带入寻找最合适的模板。


在实验中，开始是从黑色区域和白色区域各选了一块最大的区域作为样本点带入，希望能够用图像块数量最大的区域去匹配模板，但是由于有些图像的道路区域本身就是分开的或者道路上有阴影等原因，检测出来的道路区域连通性不高，这会导致模板的选择准确性不高，如图 3.12 所示，最终会影响去除虚警的效果。而且这种效果还跟道路和非道路区域的图像块数量不一样有很大关系，非道路区域和道路区域图像块数量的多少决定了它们贡献的比重，所以需要平衡样本数量来进一步平衡这个比重。

实验中最终采用了样本点数量变动的模板选取算法，其过程如下：

- 1) 通过连通性选择道路区域最大和次大的区域样本。
- 2) 通过连通性选择非道路区域最大和次大的区域样本。
- 3) 与道路模板对应位置进行比对，计算相符的道路区域和非道路区域图像块个数。
- 4) 将道路区域和非道路区域图像块的数量关系作为比例因子，使得两者的贡献率相同。
- 5) 根据正确图像个数和各自的贡献率计算出正确值最大的模板。如果有多个模板符合要求，选取第一个。



(a) 原始图像



(b) 应该选择的模板

(c) 实际选择的模板

图 3.12 道路区域不连续导致模板的选择错误

3.3 道路连通性检测降低漏检率

道路连通性的检测这个部分是为了降低识别结果的漏检率。漏检部分就是原来道路的区域由于识别率或者特殊条纹的原因没有被检测出来的道路区域。由于识别率较高，所以没有被识别出来的道路区域，即漏检部分，一般具有离散型较高，连通性不强的特点，图 3.13 中白色区域中的黑色小块就是漏检部分。针对这个特点，本文在实验中采用了连通性检测来去除漏检。这种检测方法也可以把黑色区域中离散的白色小块去除。降低漏检率后的图像如图 3.14 所示。

连通性检测降低漏检率的算法如下：

1) 对于图像中的每一个小块，以它为起点进行广度搜索，扩散颜色相同的区域，如此寻找连通区域，并计算连通区域的大小。

2) 将计算得到的连通区域的大小与阈值相比，如果连通性区域的大小小于阈值，就认为该区域是漏检，进行颜色修改，染成相反的颜色。

具体计算公式如下：

$$C_{out} = \begin{cases} C_{in}, n \geq t \\ O(C_{in}), n < t \end{cases} \quad (11)$$

其中 C_{out} 表示连通区域的处理后的颜色， C_{in} 表示连通区域处理前的颜色， n 表示连通区域的连通性，即小块个数， t 表示连通性阈值， $O(x)$ 表示将颜色变为相反的颜色，黑色变为白色，白色变为黑色。

刚开始的时候采用判断一个小图像块周围的图像块是否和它全部不一样来降低漏检率，但是这样只能去除一个独立的图像块，当只有两个图像块连在一起时，这个简单的算法就不起作用了。之后改进的算法是通过调整阈值的大小可以去除不同连通程度的区域，实验中阈值设置为 4 后，只要连通区域的大小小于 4，就会染成相反的颜色，可以看到图 3.14 将图 3.13 中白色区域中两个连通的黑色区域染成白色了。此外，可以发现白色道路区域外部的一个孤

立白色小图像块也被去除了，可见这个方法可以去除一些离散的虚警。



图 3.13 降低漏检率之前的图像



图 3.14 降低漏检率之后的图像

4 实验及评价

4.1 实验环境

影响实验的环境因素主要有三个：编译和运行环境，程序参数，以及实验数据。下面将介绍这些环境因素。

4.1.1 编译和运行环境

程序的编译和运行环境将会影响程序运行的效率。具体配置如表 4.1 所示。

表 4.1 环境配置

配置名称	具体参数
CPU	Intel Core i3-2310M @ 2.10GHz
内存容量	4GB
操作系统	Windows 7 Ultimate 64-bit
编译软件	Microsoft Visual Studio Ultimate 2013
OpenCV 版本	2.4.10

4.1.2 程序参数

程序参数主要分为 PCANet 模块的参数（见表 4.2），SVM 模块的参数（见表 4.3），先验信息辅助识别模块参数（见表 4.4）。由于不同的参数具有不同的效果，所以可以根据实际的需要设置这些参数。PCANet 模块的参数会影响特征提取的效果，SVM 模块的参数会影响分类的效果，先验信息辅助识别模块参数会影响对虚警和漏检去除的效果。表中的参数是通过实验确定的，当采用这些参数时，识别结果具有较好的效果。

表 4.2 PCANet 模块参数

参数名	参数描述	实验取值
阶段数 STAGES	PCANet 模型阶数可以根据需要增加	2
分块大小 PATCHSIZE	对输入图像进行分块时块的大小，块大小为 7×7	7
滤波器数量 L_i	决定第 i 阶段滤波器的数量，实验中阶段数为 2，所以有 L_1 和 L_2 两个值	$L_1 = L_2 = 8$
分块大小 K_1, K_2	在输出阶段也需要图像进行分块，且长和宽不 一样，块大小为 8×6	$K_1 = 8, K_2 = 6$

表 4.3 SVM 模块主要参数

参数名	参数描述	实验取值
SVM_TYPE	SVM 类型	C_SVC
C	SVM 类型参数，异常值惩罚因子 C	15
KERNEL_TYPE	核函数类型，实验中选择线性	LINEAR
MAX_ITER	最大迭代次数	100
EPSILON	精确度	e^{-6}

表 4.4 先验信息辅助识别模块参数

参数名	参数描述	实验取值
SELECTNUM	样本点数量固定的模板选取算法中点的个数	40
THREADHOLD	连通性判断的阈值	4

4.1.3 实验数据

实验的数据来自 KITTI 数据集中的道路部分。这个道路部分数据集由 289 幅训练图像和 290 幅测试图像组成。它包含城市无标记、城市标记、城市多车道标记这三种不同类型的道路场景。实验中我们去除了没有很好标记的训练图片，实际使用到了其中的 287 幅训练图片，然后编程实现对这 287 幅训练图片的再次处理，最后得到的实验数据情况如表 4.2 所示。

表 4.2 实验数据

数据类别	具体描述
原始数据	287 幅彩色道路图像和对应的 287 幅标记出道路区域的黑白图像
PCANet 训练数据	5000 幅道路区域 28×28 的图像块和 5000 幅非道路区域 28×28 的图像块，共 10000 幅
PCANet 单独测试数据	240 幅道路区域 28×28 的图像块和 240 幅非道路区域 28×28 的图像块，共 480 幅
系统整体识别数据	100 幅彩色道路图像
道路模板数据	287 幅黑白标记的块状化图像

接下来给出这些数据的一些示例。图 4.1 显示的是原始数据中的彩色道路图像，图 4.2 显示的是原始数据中的黑白道路标记图像。图 4.3 显示的是对 PCANe 模型进行训练和测试的图像，分为道路训练小块和非道路训练小块两类。用于系统整体识别的数据也如图 4.1 所示。图 4.4 显示的是将图 4.2 转换后的黑白标记的块状化图像，作为道路模板的数据。



图 4.1 原始数据彩色道路图像





图 4.2 原始数据黑白道路标记图像



道路训练小块



非道路训练小块

图 4.3 PCANet 训练和测试数据



图 4.4 黑白标记的块状化图像

4.2 程序界面

程序主要包括两个部分：一是 PCANet 模型和 SVM 的训练；二是利用训练好的识别系统识别道路区域。程序的输入输出都是图片文件，程序是控制台程序，主体界面中输出程序运行的相关信息。

图 4.5 显示的是训练 PCANet，训练 SVM 以及对训练好的模型进行测试的程序界面。在该界面中我们可以看到整个道路识别系统的训练部分主要分为三部：1 训练 PCANet 模型获得滤波器和特征向量；2 利用训练好的特征向量训练 SVM；3 对训练好的 PCANet 模型进行测试。

图 4.6 显示的是利用训练好的系统对道路图像进行识别，以及引入先验信息后的识别结果。可以看出识别过程主要分为三步：1 利用 PCANet 模型提取图像特征并使用训练好的 SVM 对判定图像的类别；2 根据模板选择算法选择合适的模板，将图像与模板进行与运算去除虚警；3 根据区域的连通性去除漏检。每一步之后都会输出计算好后的评价指标。

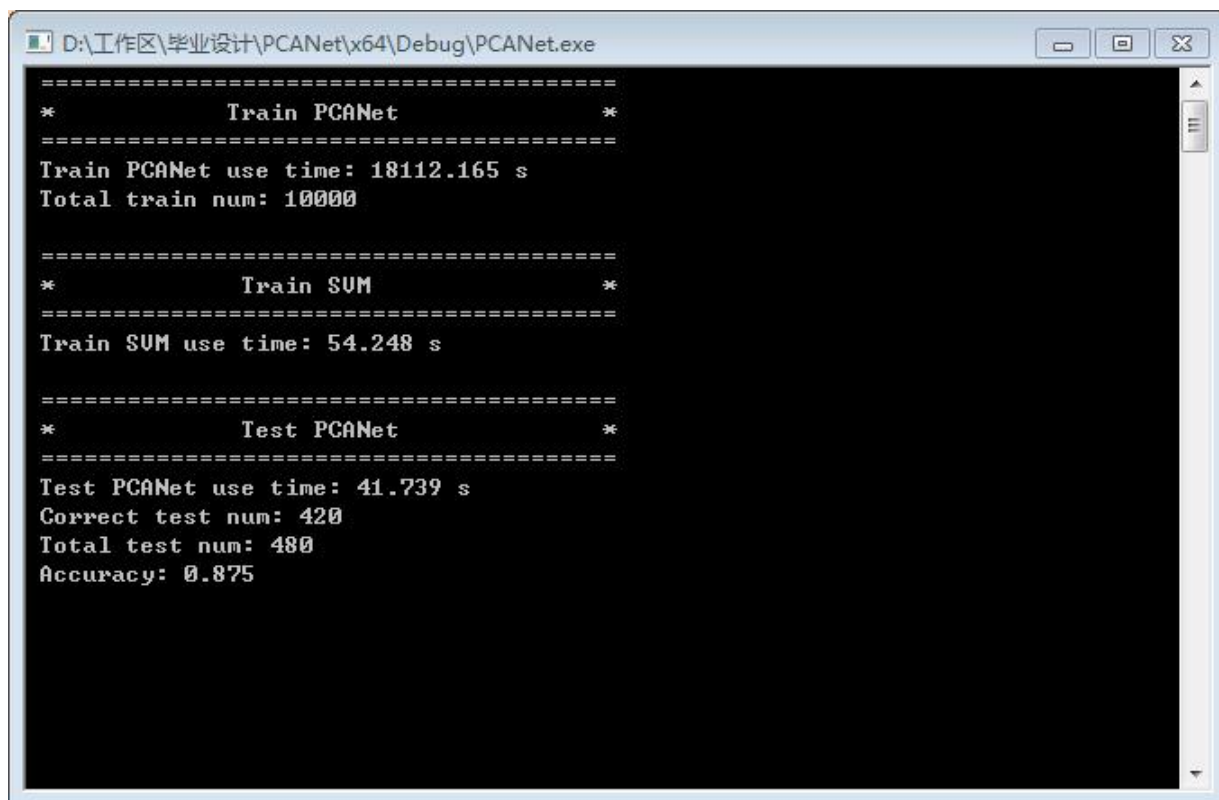


图 4.5 训练界面及结果

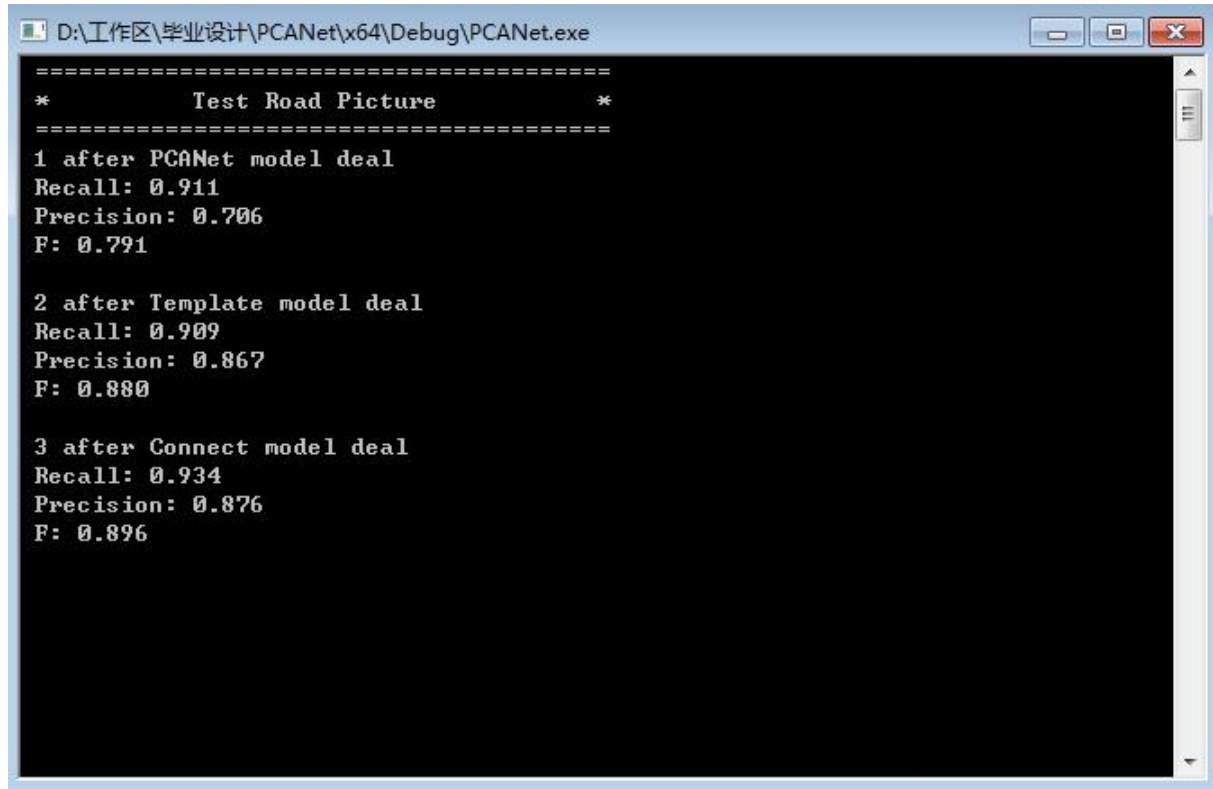


图 4.6 道路检测界面及结果

4.3 实验结果及评价

程序分为训练和识别两部分，因此评价部分也分为训练部分评价和识别部分评价两部分。实验结果的评价可以分为定性评价和定量评价两部分。定性评价主要采取主观分析识别结果的方法；定量评价需要引入相应的评价指标。模型训练部分主要是定量评价，引入先验信息后的识别部分有定量评价和定性评价两部分。

4.3.1 PCANet 模型的训练结果及评价

该部分将介绍训练部分的结果和评价。主要介绍了训练时间和训练结果。

4.3.1.1 训练时间

具体实验结果如图 4.5 所示。在该界面中，当训练数据数目是 10000 时，训练 PCANet 使用了 18112.165 秒，约为 5 个小时。利用 PCANet 提取的特征对 SVM 进行训练耗时 54.248 秒。最后用 480 图像块幅对训练好的模型进行测试，耗时 41.739 秒。

在实验中，当训练数目是 1000 时，训练 PCANet 使用了 160.33 秒，训练数据数目是 10000 时，训练时间为 18112.165 秒，可以发现当数扩大为 10 倍后，训练时间扩大了近 113 倍，这是由于实验过程中，需要将训练图像数据全部加载到内存后再进行训练，由于受到电脑内存和性能的影响，当输入图片过多后，计算机性能大幅降低，导致训练时间大幅增加，为此，在之后的测试过程中也采用分组测试的方法，这样可以大大缩短实验时间。

4.3.1.2 训练结果

对于 PCANet 模型，我们使用正确率（Accuracy）来评价。假设 N 为样本总数，T 为类别正确判断的个数，则正确率（Accuracy）的计算公式为：

$$A = \frac{T}{N} \quad (12)$$

图 4.5 所示的实验结果中，判断正确的数目 T 为 420，样本总数 N 为 480，正确率 A 为 0.875。数据样本是否具有代表性、PCANet 模型的参数以及 SVM 的参数都会影响实验的结果。为了达到 0.875 这样的正确率，实验过程中做了以下工作：对于数据样本，由于 10000 幅图像块数据量太大，我们编写程序处理数据，生成训练样本，然后对于图像中明显标记错误类别的图像进行人工修正；对于 PCANet 模型的参数，程序中使用了模型提出者实验中效果较好的参数；对于 SVM 的参数，通过改变参数值进行多次实验，最后确定实验效果较好的参数，具体参数设置见 4.1.2 小节。

4.3.2 引入先验信息后模型的定量分析

该部分将对引入先验信息后模型的识别部分进行定量分析。主要介绍了评价标准、分组

测试策略、识别结果及分析、模板选择算法实验结果分析这四部分。

4.3.2.1 评价标准

为了评价整个模型的识别效果和引入的先验信息的作用，我们使用了召回率（Recall）、精确率（Precision）、F 来对实验进行评价。

为了计算这几个指标，我们先介绍几个概念：

- TP：指实际上是道路区域的小块检测出来之后也是道路区域。
- FP：指实际上不是道路区域的小块被认为是道路区域。
- FN：指实际上是道路区域的小块被认为是非道路区域。

然后我们根据 TP，FP，FN 来计算相关指标。

- 召回率（Recall）的计算公式是：

$$R = \frac{TP}{TP + FN} \quad (13)$$

- 精确率（Precision）的计算公式是：

$$P = \frac{TP}{TP + FP} \quad (14)$$

- F 的计算公式是：

$$F = \frac{2 * P * R}{P + R} \quad (15)$$

4.3.2.2 分组测试策略

一幅带识别的图片的大小是 1232×364 ，由 572 个 28×28 的图像块组成，实验中需要测试的图片数目是 100，如果直接全部加载到内存进行测试，需要保存 57200 个 28×28 的图像块。由于计算机硬件条件的限制，当内存消耗较大时，计算机性能大大降低，因此实验中采用的方法是对实验数据进行分组测试，每 20 幅图片为一组。

4.3.2.3 识别结果及分析

测试结果如表 4.6、表 4.7、表 4.8、表 4.9 所示。表 4.6 是使用基于 PCANet 模型的分组识别结果，表 4.7 是在表 4.6 的基础上去除虚警后的结果，表 4.8 是在表 4.7 的基础上去除漏检后的结果，表 4.9 是这 100 幅图片处理结果的平均值，是需要重点分析的结果数据。

表 4.6 使用基于 PCANet 模型的分组识别结果

测试图片序号	Recall	Precision	F
01~20	0.772	0.538	0.618
21~40	0.847	0.658	0.737
41~60	0.808	0.576	0.664
61~80	0.827	0.698	0.752
81~100	0.712	0.542	0.601

表 4.7 去除虚警的分组测试结果

测试图片序号	Recall	Precision	F
01~20	0.752	0.710	0.700
21~40	0.846	0.891	0.864
41~60	0.791	0.720	0.741
61~80	0.820	0.852	0.830
81~100	0.679	0.719	0.679

表 4.8 去除漏检的分组测试结果

测试图片序号	Recall	Precision	F
01~20	0.790	0.711	0.712
21~40	0.898	0.900	0.894
41~60	0.843	0.720	0.765
61~80	0.872	0.859	0.859
81~100	0.729	0.729	0.704

表 4.9 100 幅道路图片识别结果的平均值

实验序号	实验过程	Recall	Precision	F
1	使用基于 PCANet 模型的识别系统进行处理	0.793	0.602	0.674
2	在 1 的基础上用选中的道路模板进行去除虚警处理	0.778	0.778	0.763
3	在 2 的基础上进行连通性检测降低漏检率	0.826	0.784	0.787

对表 4.9 进行分析，分析如下：

首先，从第一行的数据我们可以看到使用基于 PCANet 模型的识别系统进行处理实验效果，Recall 为 0.793，Precision 为 0.602，F 为 0.674。

其次，从第二行的数据我们可以看到，选用模板后 Recall 为 0.778，与第一行相比下降 0.015，Precision 为 0.778，与第一行相比上升 0.176，F 为 0.763，与第一行相比上升 0.089。选用模板后，由于选择的模板可能是形状相似的其他道路模板，所以可能会去除一些正确的道路区域点，所以会使得 TP 减少，导致 Recall 下降。此外选中模板能够有效地去除背景区域中的虚警，这会较大程度减小 FP 的值，所以 Precision 会上升，且上升程度较大，这也导致了 F 的上升。由此可见模板对虚警的去除是很有效果的。

接着，从第三行的数据我们可以看到，进行连通性检测后 Recall 为 0.826，与第二行相比上升 0.048，Precision 为 0.784，与第二行相比上升 0.006，F 为 0.787，上升 0.024。进行连通性检测后，会减少漏检个数，所以会使得 TP 会增加，这会导致 Recall 和 Precision 的上升，这也导致了 F 的上升。由此可见连通性检测对漏检部分的去除也是很有效果的。

最后，把模板的引入和连通性的检测作为一个整体，将第三行数据作为引入先验信息后的处理结果，与第一行数据相比，可以发现：Recall 上升 0.033，Precision 上升 0.182，F 上升 0.113。由此可见，引入的先验信息对处理效果的提升作用是相当显著的。

4.3.2.4 模板选择算法实验结果分析

在 3.2.1.3 模板选择算法这一部分中，有两种模板选择算法，表 4.10 就是这两种算法的比较。表中序号 1,2,3 是图像块数量固定的模板选取算法的处理结果，序号 1,4,5 是图像块数量变动的模板选取算法的处理结果。

单从模板选择这一步来说，图像块数量变动的模板选择方法 4 中，Recall 为 0.778，Precision

为 0.778, F 为 0.763, 图像块数量固定的模板选择方法 2 中, Recall 为 0.731, Precision 为 0.812, F 为 0.754。图像块数量变动的算法较好的保护了道路区域, 相对而言, 图像块数量固定的模板选择方法选择的模板将道路区域部分去除得过多, 使得 Recall 下降了。

从总的处理结果来说, 图像块变动的模板选择方法 5 中的 F 值为 0.787, 图像块数量固定的模板选择方法 3 中的 F 值为 0.780, 前者在处理结果上增加了 0.007。此外, 将处理结果与 1 中的对比, 仍然可以发现: 图像块数量变动的模板选择方法对最终的 Recall 和 Precision 都有提升的作用, 而图像块数量固定的选择算法降低了最终的 Recall 的值, 但是由于 Precision 增加幅度较大, 使得 F 值也增加了。可见图像块变动的模板选择方法相对较好。

表 4.10 基于 100 幅道路图片识别结果的模板选择算法比较

实验序号	实验过程	Recall	Precision	F
1	使用基于 PCANet 模型的识别系统进行处理	0.793	0.602	0.674
2	在 1 的基础上用选中的道路模板进行去除虚警处理 (图像块数量固定)	0.731	0.812	0.754
3	在 2 的基础上进行连通性检测去除漏检	0.773	0.827	0.780
4	在 1 的基础上用选中的道路模板进行去除虚警处理 (连通性决定图像块数)	0.778	0.778	0.763
5	在 4 的基础上进行连通性检测去除漏检	0.826	0.784	0.787

4.3.3 引入先验信息后模型的定性分析

除了使用召回率 (Recall)、精确率 (Precision)、F 来对实验进行评价, 我们还可以直接从图形的处理效果来对实验进行评价。最终的处理结果与 PCANet 模型的处理、使用模板去除漏检、通过连通性去除虚警这三部分有关。PCANet 模型的处理是整个系统的第一步, 它处理效果的好坏之间影响到之后的处理结果。本小节选取了较好的处理结果和较坏的处理结果对识别方法进行分析, 并列举了一些其它处理结果。

4.3.3.1 较好的处理结果

图 4.7 显示的是较好的处理结果, 其中 a 是一幅待检测的图像, b 是使用基于 PCANet 模型的处理结果, 可以看到 b 已经较好地识别出了道路部分, 但是存在一些虚警和漏检。c 是使用模板去除虚警的结果, 该过程选取了模板, 然后使用选取的模板与图像相与, 去除虚警,

我们可以看到在 c 中原来 b 中的一些分散的虚警被很好地去除了，但是图中还是存在一些漏检。d 是通过连通性检测去除漏检，我们可以看到处理后的结果很好的去除了漏检。e 是原始图像正确的黑白标记图片，将程序的识别结果 d 与始图像正确的处理结果 e 进行对比可以发现，识别效果是非常不错的，大部分道路区域都有效地识别了出来。



(a) 待检测道路图像



(b) 基于 PCANet 模型的识别结果



(c) 使用模板去除虚警



(d) 通过连通性检测去除漏检



(e) 原始图像正确的处理结果

图 4.7 较好的处理结果

4.3.3.2 较差的处理结果

图 4.8 显示的是基于 PCANet 模型的识别问题导致的较差处理结果。从图中我们可以看到由于道路区域存在阴影等问题，导致基于 PCANet 模型的识别结果不是很好，这导致了选择模板过程中的图像块不具有很好的代表性，影响了模板的选择，因此模板对虚警的去除效果受到了影响。b 中较差的识别结果也使得整体的连通性不高，这也使用连通性去除漏检这个模块的处理效果不佳。最终导致了较差的处理结果。



(a) 输入图像

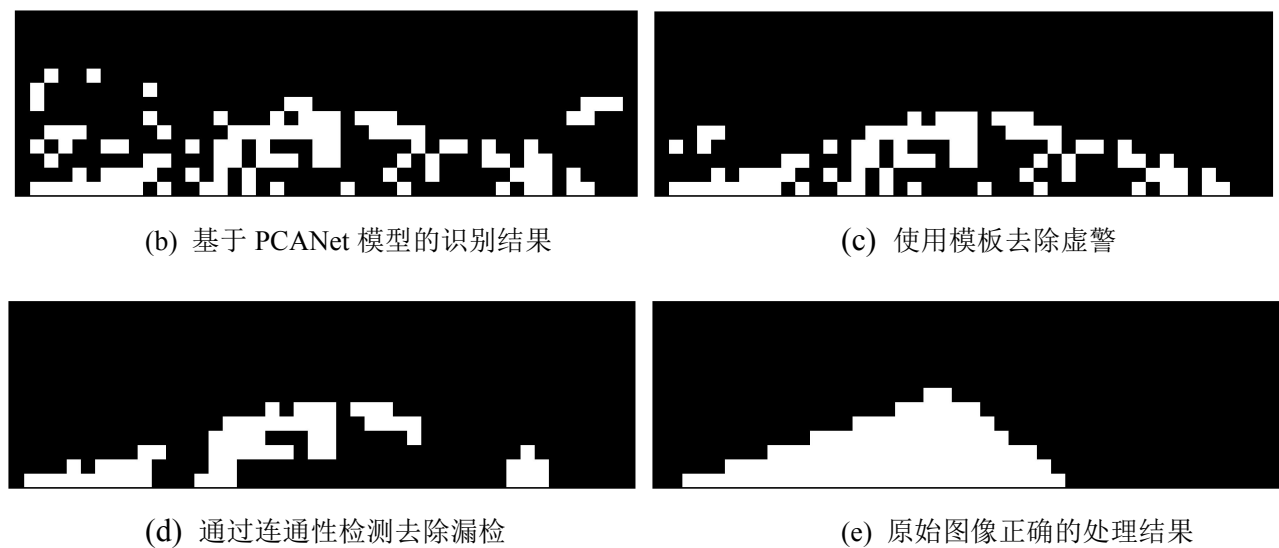


图 4.8 基于 PCANet 模型的识别问题导致的较差处理结果

4.3.3.3 其它处理结果

我们再看一些其它场景的识别结果。图 4.9 是含有汽车、铁轨、草地等元素输入图像处理结果，从此图的处理结果可以看出，该识别方法能够较好地识别那些含有区别于道路区域的元素的输入图像。

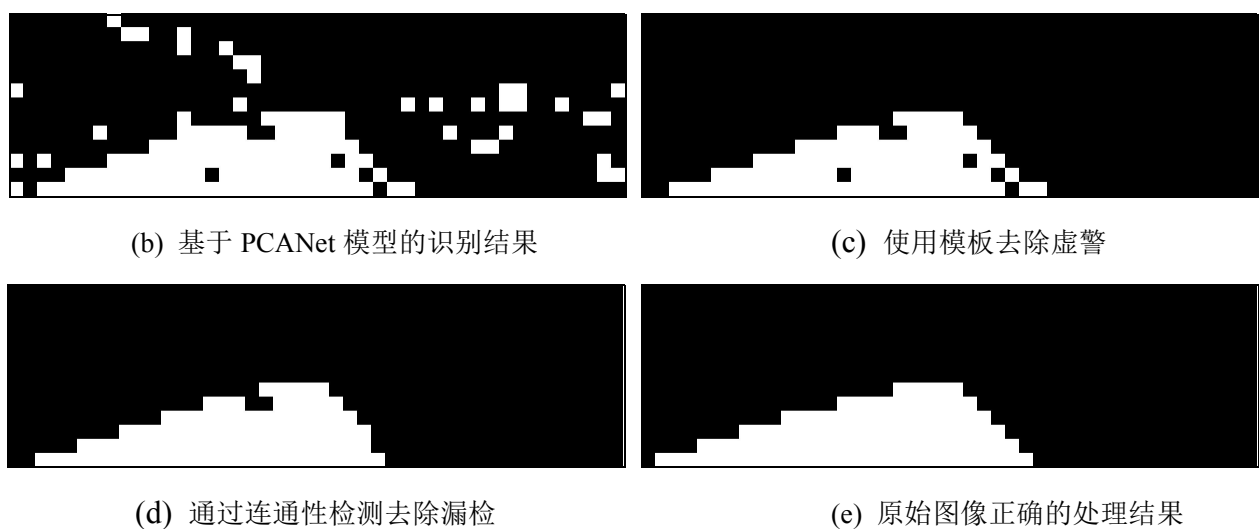


图 4.9 含有汽车、铁轨、草地等元素输入图像处理结果

图 4.10 显示的是三岔路口的识别结果。可以看到最后的结果与正确的处理结果还是很相近的。从 c 到 d 的步骤中，可以发现连通性检测虽然可以补全不完整的区域，但也可能把正确的部分去掉，所以该步骤的效果很大程度上依赖于之前几步的处理效果。

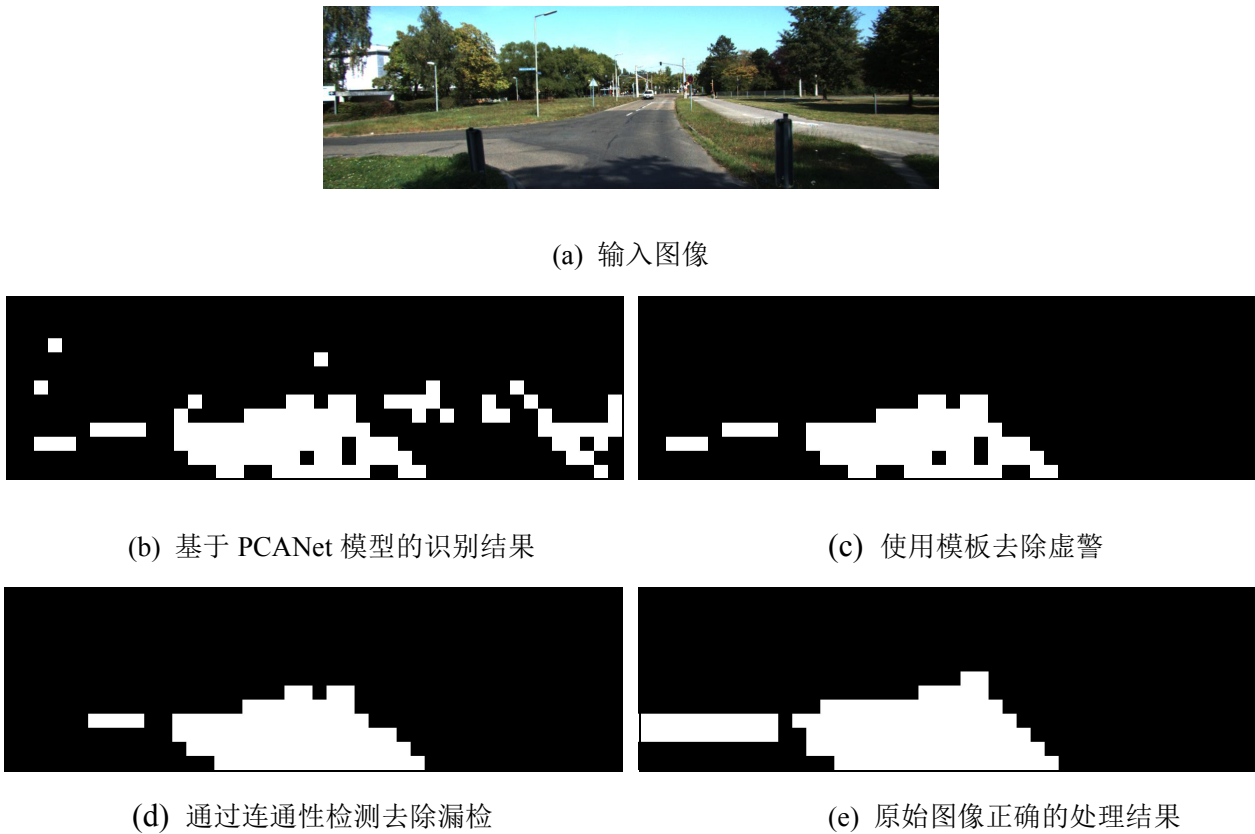
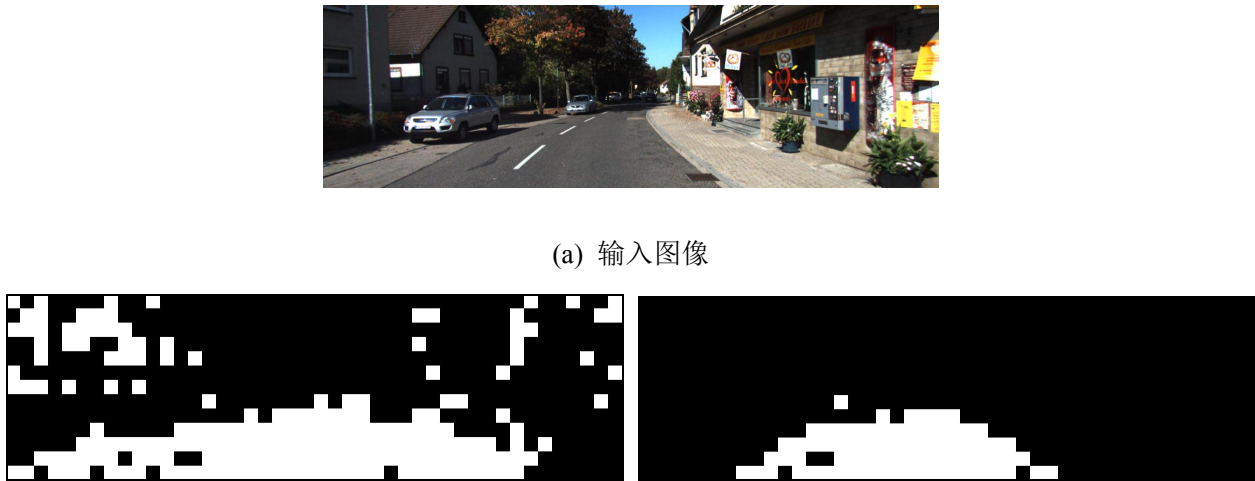


图 4.10 三岔路口输入图像处理结果

图 4.11 显示的是含有房屋等元素输入图像处理结果。可以发现，由于背景中的房屋与道路的质地差不多，很容易造成错误的识别，b 中上方部分出现了很多错误的识别。此外，c 中可以看到，模板的选择对于这种错误识别是具有很好的修正作用的。






图 4.11 含有房屋等元素输入图像处理结

结 论

本文的目的是识别道路场景中的道路区域，根据实验结果可知，本文提出的识别方法具有较好的效果，为了达到这个效果，本次毕业设计主要做了以下工作：

- 1) 详细研究了 PCANet 模型，分析了其算法复杂度，最后使用 C++ 编程实现了该模型，并了解和学习了 SVM，在程序中调用了 OpenCV 中的 SVM 部分实现了 SVM 模块。
- 2) 为了去除虚警，采用了选择模板的方法，根据实际效果，从开始合成的单一模板变为最后的多个模板，有效地去除了虚警。为了降低漏检率，采用了连通性检测的方法，从开始的简单地观察像素四周的染色情况到最后使用广度搜索来判断连通性，有效地降低了漏检率。
- 3) 通过多次实验，最终确定了一系列效果较好的实验参数。此外，除了主体的识别程序，为了获得足够多的样本，还编程实现了训练样本的获取，以及在模板生成部分也编程实现了 287 幅图像模板的块状化处理。
- 4) 进行了实验，根据实验结果，不仅对 PCANet 模型进行了评价，也对引入先验信息模块的作用进行了评价。

虽然做了以上的工作，但本文提出的引入先验信息的基于 PCANet 模型的道路识别方法还是需要进一步的完善，后续的工作主要可以从以下几个方面开展：

- 1) 如何在特征提取过程中引入位置信息提高特征的代表性从而提高识别率。
- 2) 如何提高模板选择的鲁棒性，在基于 PCANet 模型的识别模块识别效果不好的情况下，避免错误图像块的干扰，利用大体轮廓找到相似的模板。
- 3) 程序运行时对内存的消耗较大，如何进一步提高程序效率也有待研究。
- 4) 本文针对的是道路区域的识别，但是同样适用于车辆等道路目标的识别，只要替换训练样本就行了，所以可以进一步将车辆的识别融入进来。

致 谢

大学四年过得很快，在这四年中充满了挑战和快乐。在这四年的成长过程中，我要感谢所有曾经教育和帮助过我的老师和同学们，感谢他们无私的帮助。我还要感谢家人默默的支持，正是他们的支持才让我能够安心学习。

本次毕业设计特别要感谢王欢老师，正是王欢老师耐心的讲解和认真的辅导才让我能够顺利完成这次毕设。在此向王欢老师表示衷心的感谢！王欢老师严谨的治学态度和的渊博专业知识给我留下了深刻印象，使我受益匪浅。

最后非常感谢计算机学院的相关领导和老师的关心和帮助，在此表达最真挚的谢意。

参 考 文 献

- [1] 邓维. 基于道路地形图的道路识别技术研究[D]. 长沙: 湖南大学, 2014.
- [2] 朱钊. 基于 DSP 道路识别技术研究[D]. 武汉: 武汉理工大学, 2010.
- [3] 丁俊进. 基于机器视觉道路识别技术的研究[D]. 武汉: 武汉理工大学, 2007.
- [4] 王荣本, 游峰, 崔高健等. 基于计算机视觉高速智能车辆的道路识别[J]. 计算机工程与应用, 2004, 40(26):18-21.
- [5] 王忠. 基于视觉的道路识别技术在智能小车导航中的应用研究[D]. 南京: 东南大学, 2006.
- [6] 董瑞先. 基于计算机视觉的道路识别方法的研究[D]. 青岛: 青岛大学, 2010.
- [7] 孙畅. 车辆辅助驾驶中基于 DSP 的道路行人识别算法研究[D]. 长春: 吉林大学, 2013.
- [8] 吴玉月, 冯能莲, 王继先. 基于视觉的 AGV 自动运输车道路识别技术研究[J]. 机械制造, 2010, 48(9):35-37.
- [9] 李陆. 移动机器人视觉导航中的道路检测技术研究[D]. 重庆: 重庆大学, 2012.
- [10] 徐友春, 王荣本, 李克强等. 一种基于直线模型的道路识别算法研究[J]. 中国图象图形学报: , 2004, 9(7):858-864.
- [11] 魏武, 龚树锋. 基于机器视觉的非结构化道路检测算法研究[J]. 传感器与微系统, 2010, 29(1):39-41.
- [12] 董瑞先, 王玉林, 张鲁邹等. 一种基于直线模型的道路识别算法[J]. 青岛大学学报: 工程技术版, 2010, 25(1).
- [13] Chan T, Jia K, Gao S, et al. PCANet: A Simple Deep Learning Baseline for Image Classification?[J]. eprint arXiv:1404.3606, 2014.
- [14] A W, K. H. Local PCA algorithms[J]. IEEE Transactions on Neural Networks, 2000, 11(6):1242 - 1250.
- [15] 祁亨年. 支持向量机及其应用研究综述[J]. 计算机工程, 2004, 30(10):6-9.
- [16] 杨正帅. 基于视觉的道路识别技术在移动机器人导航中的应用研究[D]. 南京: 南京理工大学, 2007.